

# Probabilidad y estadística para la Inteligencia Artificial, clase 6

Camilo Enrique Argoty Pulido

Especialización en Inteligencia Artificial

15 de abril de 2025



## Origen de la inferencia estadística

# Determinar la verdad: El ejemplo del sistema judicial

A lo largo de la historia, siempre ha existido el problema de determinar de los hechos a nivel judicial

# Determinar la verdad: El ejemplo del sistema judicial

A lo largo de la historia, siempre ha existido el problema de determinar de los hechos a nivel judicial

Por ello, en derecho se habla de la **verdad verdadera** y la **verdad judicial**

# Determinar la verdad: El ejemplo del sistema judicial

A lo largo de la historia, siempre ha existido el problema de determinar de los hechos a nivel judicial

Por ello, en derecho se habla de la **verdad verdadera** y la **verdad judicial**

- La **verdad verdadera** es la realidad de los hechos. Suele ser imposible de conocer con total seguridad.

# Determinar la verdad: El ejemplo del sistema judicial

A lo largo de la historia, siempre ha existido el problema de determinar de los hechos a nivel judicial

Por ello, en derecho se habla de la **verdad verdadera** y la **verdad judicial**

- La **verdad verdadera** es la realidad de los hechos. Suele ser imposible de conocer con total seguridad.
- La **verdad judicial** es lo que se puede establecer de los hechos a partir a partir de las evidencias. Puede ser distinta a la verdad verdadera.

# La presunción de inocencia

Como todos sabemos, puede haber dos tipos de injusticias que se pueden cometer en un juicio:

# La presunción de inocencia

Como todos sabemos, puede haber dos tipos de injusticias que se pueden cometer en un juicio:

**Injusticia I:** Condenar un inocente.



# La presunción de inocencia

Como todos sabemos, puede haber dos tipos de injusticias que se pueden cometer en un juicio:

**Injusticia I:** Condenar un inocente.

**Injusticia II:** Absolver un culpable

# La presunción de inocencia

Como todos sabemos, puede haber dos tipos de injusticias que se pueden cometer en un juicio:

**Injusticia I:** Condenar un inocente.

**Injusticia II:** Absolver un culpable

En la sociedad occidental moderna se considera peor cometer la Injusticia I que la Injusticia II.

# La presunción de inocencia

Como todos sabemos, puede haber dos tipos de injusticias que se pueden cometer en un juicio:

**Injusticia I:** Condenar un inocente.

**Injusticia II:** Absolver un culpable

En la sociedad occidental moderna se considera peor cometer la Injusticia I que la Injusticia II.

Por lo anterior, el proceso para establecer la verdad judicial está determinado por el denominado **Principio de Presunción de Inocencia:**

# La presunción de inocencia

Como todos sabemos, puede haber dos tipos de injusticias que se pueden cometer en un juicio:

**Injusticia I:** Condenar un inocente.

**Injusticia II:** Absolver un culpable

En la sociedad occidental moderna se considera peor cometer la Injusticia I que la Injusticia II.

Por lo anterior, el proceso para establecer la verdad judicial está determinado por el denominado **Principio de Presunción de Inocencia:**

**Toda persona es inocente hasta que se demuestre lo contrario**

# ¿Qué es **demostrar culpabilidad**?

En un tribunal, ante el juez se presentan las evidencias y contra-evidencias.

# ¿Qué es **demostrar culpabilidad**?

En un tribunal, ante el juez se presentan las evidencias y contra-evidencias.

Pero, ¿qué proceso se sigue para determinar si se ha demostrado la culpabilidad o no?

# ¿Qué es **demostrar culpabilidad**?

En un tribunal, ante el juez se presentan las evidencias y contra-evidencias.

Pero, ¿qué proceso se sigue para determinar si se ha demostrado la culpabilidad o no?

Fundamentalmente, lo que el juez determina es si, asumiendo la inocencia, es o no creíble que existan las evidencias que se presentan.

# ¿Qué es **demostrar culpabilidad**?

En un tribunal, ante el juez se presentan las evidencias y contra-evidencias.

Pero, ¿qué proceso se sigue para determinar si se ha demostrado la culpabilidad o no?

Fundamentalmente, lo que el juez determina es si, asumiendo la inocencia, es o no creíble que existan las evidencias que se presentan.

Si, asumiendo la inocencia del acusado, es creíble que existan las evidencias que se presentan.



# ¿Qué es demostrar culpabilidad?

En un tribunal, ante el juez se presentan las evidencias y contra-evidencias.

Pero, ¿qué proceso se sigue para determinar si se ha demostrado la culpabilidad o no?

Fundamentalmente, lo que el juez determina es si, asumiendo la inocencia, es o no creíble que existan las evidencias que se presentan.

Si, asumiendo la inocencia del acusado, es creíble que existan las evidencias que se presentan.

Si, por el contrario y asumiendo la inocencia del acusado, las evidencias son de difícil ocurrencia, entonces se considera que la culpabilidad ha sido demostrada.

# Traducción a lenguaje estadístico

Si se traduce esto a lenguaje estadístico, se resumiría de la siguiente manera:

# Traducción a lenguaje estadístico

Si se traduce esto a lenguaje estadístico, se resumiría de la siguiente manera:

Si  $P(\text{Evidencias} \mid \text{El acusado es inocente})$  es menor que un cierto umbral, entonces se considera que la culpabilidad se ha demostrado. Si no, se declara inocente al acusado.

# Traducción a lenguaje estadístico

Si se traduce esto a lenguaje estadístico, se resumiría de la siguiente manera:

Si  $P(\text{Evidencias} \mid \text{El acusado es inocente})$  es menor que un cierto umbral, entonces se considera que la culpabilidad se ha demostrado. Si no, se declara inocente al acusado.

Este umbral se denomina **significancia** o **significación estadística**.

# Traducción a lenguaje estadístico

Si se traduce esto a lenguaje estadístico, se resumiría de la siguiente manera:

Si  $P(\text{Evidencias} \mid \text{El acusado es inocente})$  es menor que un cierto umbral, entonces se considera que la culpabilidad se ha demostrado. Si no, se declara inocente al acusado.

Este umbral se denomina **significancia** o **significación estadística**.

Por otro lado, en estadística las evidencias se convierten en funciones calculadas a partir de los datos experimentales. En otras palabras, **estadísticos**. Estos estadísticos se denominan **estadísticos de prueba**.

# Traducción a lenguaje estadístico

Si se traduce esto a lenguaje estadístico, se resumiría de la siguiente manera:

Si  $P(\text{Evidencias} \mid \text{El acusado es inocente})$  es menor que un cierto umbral, entonces se considera que la culpabilidad se ha demostrado. Si no, se declara inocente al acusado.

Este umbral se denomina **significancia** o **significación estadística**.

Por otro lado, en estadística las evidencias se convierten en funciones calculadas a partir de los datos experimentales. En otras palabras, **estadísticos**. Estos estadísticos se denominan **estadísticos de prueba**.

El valor  $P(\text{Evidencias} \mid \text{El acusado es inocente})$  se denomina **p-valor**

# La hipótesis nula y la hipótesis alternativa

En estadística, una **hipótesis** es una afirmación sobre una o varias variables aleatorias, en general sobre parámetros como la media o la varianza.

# La hipótesis nula y la hipótesis alternativa

En estadística, una **hipótesis** es una afirmación sobre una o varias variables aleatorias, en general sobre parámetros como la media o la varianza.

Así, en inferencia estadística siempre se confrontan 2 hipótesis:



# La hipótesis nula y la hipótesis alternativa

En estadística, una **hipótesis** es una afirmación sobre una o varias variables aleatorias, en general sobre parámetros como la media o la varianza.

Así, en inferencia estadística siempre se confrontan 2 hipótesis:

$H_0$ : **Hipótesis nula**. Se presume, es decir, se considera verdadera y no debe demostrarse.

# La hipótesis nula y la hipótesis alternativa

En estadística, una **hipótesis** es una afirmación sobre una o varias variables aleatorias, en general sobre parámetros como la media o la varianza.

Así, en inferencia estadística siempre se confrontan 2 hipótesis:

$H_0$ : **Hipótesis nula**. Se presume, es decir, se considera verdadera y no debe demostrarse.

$H_1$ : **Hipótesis alternativa**. No se presume. Debe demostrarse.

# La hipótesis nula y la hipótesis alternativa

En estadística, una **hipótesis** es una afirmación sobre una o varias variables aleatorias, en general sobre parámetros como la media o la varianza.

Así, en inferencia estadística siempre se confrontan 2 hipótesis:

$H_0$ : **Hipótesis nula**. Se presume, es decir, se considera verdadera y no debe demostrarse.

$H_1$ : **Hipótesis alternativa**. No se presume. Debe demostrarse.

Con respecto a estas hipótesis, se pueden cometer los siguientes errores:

# La hipótesis nula y la hipótesis alternativa

En estadística, una **hipótesis** es una afirmación sobre una o varias variables aleatorias, en general sobre parámetros como la media o la varianza.

Así, en inferencia estadística siempre se confrontan 2 hipótesis:

$H_0$ : **Hipótesis nula**. Se presume, es decir, se considera verdadera y no debe demostrarse.

$H_1$ : **Hipótesis alternativa**. No se presume. Debe demostrarse.

Con respecto a estas hipótesis, se pueden cometer los siguientes errores:

**Error tipo I:** Rechazar  $H_0$  siendo esta verdadera.

# La hipótesis nula y la hipótesis alternativa

En estadística, una **hipótesis** es una afirmación sobre una o varias variables aleatorias, en general sobre parámetros como la media o la varianza.

Así, en inferencia estadística siempre se confrontan 2 hipótesis:

$H_0$ : **Hipótesis nula**. Se presume, es decir, se considera verdadera y no debe demostrarse.

$H_1$ : **Hipótesis alternativa**. No se presume. Debe demostrarse.

Con respecto a estas hipótesis, se pueden cometer los siguientes errores:

**Error tipo I:** Rechazar  $H_0$  siendo esta verdadera.

**Error tipo II:** No rechazar  $H_0$  siendo esta falsa.

# Funcionamiento general de una prueba de hipótesis I

Por lo anterior, funcionamiento general de una prueba de hipótesis es de la siguiente manera. O bien,

# Funcionamiento general de una prueba de hipótesis I

Por lo anterior, funcionamiento general de una prueba de hipótesis es de la siguiente manera. O bien,

$$H_0 : \theta = \theta_0$$

$$H_1 : \theta \neq \theta_0$$

# Funcionamiento general de una prueba de hipótesis I

Por lo anterior, funcionamiento general de una prueba de hipótesis es de la siguiente manera. O bien,

$$H_0 : \theta = \theta_0$$

$$H_1 : \theta \neq \theta_0$$

o bien,



# Funcionamiento general de una prueba de hipótesis I

Por lo anterior, funcionamiento general de una prueba de hipótesis es de la siguiente manera. O bien,

$$H_0 : \theta = \theta_0$$

$$H_1 : \theta \neq \theta_0$$

o bien,

$$H_0 : \theta = \theta_0$$

$$H_1 : \theta > \theta_0$$

# Funcionamiento general de una prueba de hipótesis I

Por lo anterior, funcionamiento general de una prueba de hipótesis es de la siguiente manera. O bien,

$$H_0 : \theta = \theta_0$$

$$H_1 : \theta \neq \theta_0$$

o bien,

$$H_0 : \theta = \theta_0$$

$$H_1 : \theta > \theta_0$$

o bien,

$$H_0 : \theta = \theta_0$$

$$H_1 : \theta < \theta_0$$

# Funcionamiento general de una prueba de hipótesis I

Por lo anterior, funcionamiento general de una prueba de hipótesis es de la siguiente manera. O bien,

$$H_0 : \theta = \theta_0$$

$$H_1 : \theta \neq \theta_0$$

o bien,

$$H_0 : \theta = \theta_0$$

$$H_1 : \theta > \theta_0$$

o bien,

$$H_0 : \theta = \theta_0$$

$$H_1 : \theta < \theta_0$$

La primera se conoce como **prueba bilateral o de dos colas**, mientras que las otras se conocen como **pruebas unilaterales o de una cola**.

# Funcionamiento general de una prueba de hipótesis II

En ambos casos se calcula un **estadístico de prueba**  $T_0 = T(X_1, X_2, \dots, x_n)$  con base en los datos, a partir del cual se calcula:

# Funcionamiento general de una prueba de hipótesis II

En ambos casos se calcula un **estadístico de prueba**  $T_0 = T(X_1, X_2, \dots, x_n)$  con base en los datos, a partir del cual se calcula:

$$p = P(T > T_0 | H_0)$$

# Funcionamiento general de una prueba de hipótesis II

En ambos casos se calcula un **estadístico de prueba**  $T_0 = T(X_1, X_2, \dots, x_n)$  con base en los datos, a partir del cual se calcula:

$$p = P(T > T_0 | H_0)$$

Si  $p < \alpha$ , se rechaza  $H_0$ .

## Ejemplos de pruebas de hipótesis

# Media con varianza conocida

Procedimiento de  
prueba para una  
sola media

(varianza  
conocida)

$$z = \frac{\bar{x} - \mu_0}{\sigma/\sqrt{n}} > z_{\alpha/2} \quad \text{o} \quad z = \frac{\bar{x} - \mu_0}{\sigma/\sqrt{n}} < -z_{\alpha/2}$$

Si  $-z_{\alpha/2} < z < z_{\alpha/2}$ , no se rechaza  $H_0$ . El rechazo de  $H_0$ , desde luego, implica la aceptación de la hipótesis alternativa  $\mu \neq \mu_0$ . Con esta definición de la región crítica debería quedar claro que habrá  $\alpha$  probabilidades de rechazar  $H_0$  (al caer en la región crítica) cuando, en realidad,  $\mu = \mu_0$ .



# Media con varianza conocida

Procedimiento de  
prueba para una  
sola media

$$z = \frac{\bar{x} - \mu_0}{\sigma/\sqrt{n}} > z_{\alpha/2} \quad \text{o} \quad z = \frac{\bar{x} - \mu_0}{\sigma/\sqrt{n}} < -z_{\alpha/2}$$

(varianza  
conocida)

Si  $-z_{\alpha/2} < z < z_{\alpha/2}$ , no se rechaza  $H_0$ . El rechazo de  $H_0$ , desde luego, implica la aceptación de la hipótesis alternativa  $\mu \neq \mu_0$ . Con esta definición de la región crítica debería quedar claro que habrá  $\alpha$  probabilidades de rechazar  $H_0$  (al caer en la región crítica) cuando, en realidad,  $\mu = \mu_0$ .

Un fabricante de equipo deportivo desarrolló un nuevo sedal para pesca sintético que, según afirma, tiene una resistencia media a la rotura de 8 kilogramos con una desviación estándar de 0.5 kilogramos. Pruebe la hipótesis de que  $\mu = 8$  kilogramos contra la alternativa de que  $\mu \neq 8$  kilogramos si se prueba una muestra aleatoria de 50 sedales y se encuentra que tienen una resistencia media a la rotura de 7.8 kilogramos. Utilice un nivel de significancia de 0.01.

# Media con varianza conocida

1.  $H_0: \mu = 8$  kilogramos.
2.  $H_1: \mu \neq 8$  kilogramos.
3.  $\alpha = 0.01$ .
4. Región crítica:  $z < -2.575$  y  $z > 2.575$ , donde  $z = \frac{\bar{x} - \mu_0}{\sigma/\sqrt{n}}$ .
5. Cálculos:  $\bar{x} = 7.8$  kilogramos,  $n = 50$ , en consecuencia,  $z = \frac{7.8 - 8}{0.5/\sqrt{50}} = -2.83$ .
6. Decisión: rechazar  $H_0$  y concluir que la resistencia promedio a la rotura no es igual a 8 sino que, de hecho, es menor que 8 kilogramos.

Como la prueba en este ejemplo es de dos colas, el valor de  $P$  que se desea es el doble del área de la región sombreada en la figura 10.11 a la izquierda de  $z = -2.83$ . Por lo tanto, si usamos la tabla A.3, tenemos

$$P = P(|Z| > 2.83) = 2P(Z < -2.83) = 0.0046,$$

que nos permite rechazar la hipótesis nula de que  $\mu = 8$  kilogramos a un nivel de significancia menor que 0.01.

# Media con varianza desconocida

El estadístico  $t$  Para la hipótesis bilateral  
para una prueba  
sobre una sola  
media (varianza  
desconocida)

$$H_0: \mu = \mu_0,$$

$$H_1: \mu \neq \mu_0,$$

rechazamos  $H_0$  a un nivel de significancia  $\alpha$  cuando el estadístico  $t$  calculado

$$t = \frac{\bar{x} - \mu_0}{s/\sqrt{n}}$$

excede a  $t_{\alpha/2, n-1}$  o es menor que  $-t_{\alpha/2, n-1}$ .

# Media con varianza desconocida

El estadístico  $t$  Para la hipótesis bilateral  
para una prueba  
sobre una sola  
media (varianza  
desconocida)

$$H_0: \mu = \mu_0,$$

$$H_1: \mu \neq \mu_0,$$

rechazamos  $H_0$  a un nivel de significancia  $\alpha$  cuando el estadístico  $t$  calculado

$$t = \frac{\bar{x} - \mu_0}{s/\sqrt{n}}$$

excede a  $t_{\alpha/2, n-1}$  o es menor que  $-t_{\alpha/2, n-1}$ .

El Edison Electric Institute publica cifras del número de kilowatts-hora que gastan anualmente varios aparatos electrodomésticos. Se afirma que una aspiradora gasta un promedio de 46 kilowatts-hora al año. Si una muestra aleatoria de 12 hogares, que se incluye en un estudio planeado, indica que las aspiradoras gastan un promedio de 42 kilowatts-hora al año con una desviación estándar de 11.9 kilowatts-hora, ¿esto sugiere que las aspiradoras gastan, en promedio, menos de 46 kilowatts-hora al año a un nivel de significancia de 0.05? Suponga que la población de kilowatts-hora es normal.

# Media con varianza desconocida

1.  $H_0: \mu = 46$  kilowatts-hora.
2.  $H_1: \mu < 46$  kilowatts-hora.
3.  $\alpha = 0.05$ .
4. Región crítica:  $t < -1.796$ , donde  $t = \frac{\bar{x} - \mu_0}{s / \sqrt{n}}$  con 11 grados de libertad.
5. Cálculos:  $\bar{x} = 42$  kilowatts-hora,  $s = 11.9$  kilowatts-hora y  $n = 12$ .  
En consecuencia,

$$t = \frac{42 - 46}{11.9 / \sqrt{12}} = -1.16, \quad P = P(T < -1.16) \approx 0.135.$$

6. Decisión: no rechazar  $H_0$  y concluir que el número promedio de kilowatts-hora que gastan al año las aspiradoras domésticas no es significativamente menor que 46. ─

# Prueba $t$ dos muestras con varianzas desconocidas

Prueba  $t$  Para la hipótesis bilateral  
agrupada de  
dos muestras

$$H_0: \mu_1 = \mu_2,$$

$$H_1: \mu_1 \neq \mu_2,$$

rechazamos  $H_0$  al nivel de significancia  $\alpha$  cuando el estadístico  $t$  calculado

$$t = \frac{(\bar{x}_1 - \bar{x}_2) - d_0}{s_p \sqrt{1/n_1 + 1/n_2}},$$

donde

$$s_p^2 = \frac{s_1^2(n_1 - 1) + s_2^2(n_2 - 1)}{n_1 + n_2 - 2}$$

excede a  $t_{\alpha/2, n_1 + n_2 - 2}$  o es menor que  $-t_{\alpha/2, n_1 + n_2 - 2}$ .

# Prueba $t$ dos muestras con varianzas desconocidas

Se llevó a cabo un experimento para comparar el desgaste por abrasivos de dos diferentes materiales laminados. Se probaron 12 piezas del material 1 exponiendo cada pieza a una máquina para medir el desgaste. Se probaron 10 piezas del material 2 de manera similar. En cada caso se observó la profundidad del desgaste. Las muestras del material 1 revelaron un desgaste promedio (codificado) de 85 unidades con una desviación estándar muestral de 4; en tanto que las muestras del material 2 revelaron un promedio de 81 y una desviación estándar muestral de 5. ¿Podríamos concluir, a un nivel de significancia de 0.05, que el desgaste abrasivo del material 1 excede al del material 2 en más de 2 unidades? Suponga que las poblaciones son aproximadamente normales con varianzas iguales.

# Prueba $t$ dos muestras con varianzas desconocidas

Representemos con  $\mu_1$  y  $\mu_2$  las medias de la población del desgaste abrasivo para el material 1 y el material 2, respectivamente.

1.  $H_0: \mu_1 - \mu_2 = 2$ .
2.  $H_1: \mu_1 - \mu_2 > 2$ .
3.  $\alpha = 0.05$ .
4. Región crítica:  $t > 1.725$ , donde  $t = \frac{(\bar{x}_1 - \bar{x}_2) - d_0}{s_p \sqrt{1/n_1 + 1/n_2}}$  con  $v = 20$  grados de libertad.

5. Cálculos:

$$\begin{aligned}\bar{x}_1 &= 85, & s_1 &= 4, & n_1 &= 12, \\ \bar{x}_2 &= 81, & s_2 &= 5, & n_2 &= 10.\end{aligned}$$

En consecuencia,

$$s_p = \sqrt{\frac{(11)(16) + (9)(25)}{12 + 10 - 2}} = 4.478,$$

$$t = \frac{(85 - 81) - 2}{4.478 \sqrt{1/12 + 1/10}} = 1.04,$$

$$P = P(T > 1.04) \approx 0.16. \quad (\text{Véase la tabla A.4}).$$

6. Decisión: no rechazar  $H_0$ . No podemos concluir que el desgaste abrasivo del material 1 excede al del material 2 en más de 2 unidades.



# Tabla pruebas con medias varianza conocida

$H_0$	Valor del estadístico de prueba	$H_1$	Región crítica
$\mu = \mu_0$	$z = \frac{\bar{x} - \mu_0}{\sigma/\sqrt{n}}; \sigma \text{ conocida}$	$\mu < \mu_0$	$z < -z_\alpha$
		$\mu > \mu_0$	$z > z_\alpha$
		$\mu \neq \mu_0$	$z < -z_{\alpha/2} \text{ o } z > z_{\alpha/2}$
$\mu = \mu_0$	$t = \frac{\bar{x} - \mu_0}{s/\sqrt{n}}; v = n - 1, \sigma \text{ desconocida}$	$\mu < \mu_0$	$t < -t_\alpha$
		$\mu > \mu_0$	$t > t_\alpha$
		$\mu \neq \mu_0$	$t < -t_{\alpha/2} \text{ o } t > t_{\alpha/2}$
$\mu_1 - \mu_2 = d_0$	$z = \frac{(\bar{x}_1 - \bar{x}_2) - d_0}{\sqrt{\sigma_1^2/n_1 + \sigma_2^2/n_2}}; \sigma_1 \text{ y } \sigma_2 \text{ conocidas}$	$\mu_1 - \mu_2 < d_0$	$z < -z_\alpha$
		$\mu_1 - \mu_2 > d_0$	$z > z_\alpha$
		$\mu_1 - \mu_2 \neq d_0$	$z < -z_{\alpha/2} \text{ o } z > z_{\alpha/2}$

# Tabla pruebas con medias varianza desconocida

$\mu_1 - \mu_2 = d_0$	$t = \frac{(\bar{x}_1 - \bar{x}_2) - d_0}{s_p \sqrt{1/n_1 + 1/n_2}};$ $v = n_1 + n_2 - 2,$ $\sigma_1 = \sigma_2 \text{ pero desconocidas}$ $s_p^2 = \frac{(n_1 - 1)s_1^2 + (n_2 - 1)s_2^2}{n_1 + n_2 - 2}$	$\mu_1 - \mu_2 < d_0$ $\mu_1 - \mu_2 > d_0$ $\mu_1 - \mu_2 \neq d_0$	$t < -t_\alpha$ $t > t_\alpha$ $t < -t_{\alpha/2} \text{ o } t > t_{\alpha/2}$
$\mu_1 - \mu_2 = d_0$	$t' = \frac{(\bar{x}_1 - \bar{x}_2) - d_0}{\sqrt{s_1^2/n_1 + s_2^2/n_2}};$ $v = \frac{(s_1^2/n_1 + s_2^2/n_2)^2}{\frac{(s_1^2/n_1)^2}{n_1 - 1} + \frac{(s_2^2/n_2)^2}{n_2 - 1}},$ $\sigma_1 \neq \sigma_2 \text{ y desconocidas}$	$\mu_1 - \mu_2 < d_0$ $\mu_1 - \mu_2 > d_0$ $\mu_1 - \mu_2 \neq d_0$	$t' < -t_\alpha$ $t' > t_\alpha$ $t' < -t_{\alpha/2} \text{ o } t' > t_{\alpha/2}$
$\mu_D = d_0$ observaciones pareadas	$t = \frac{\bar{d} - d_0}{s_d/\sqrt{n}};$ $v = n - 1$	$\mu_D < d_0$ $\mu_D > d_0$ $\mu_D \neq d_0$	$t < -t_\alpha$ $t > t_\alpha$ $t < -t_{\alpha/2} \text{ o } t > t_{\alpha/2}$

# ANOVA

$$\sum_i \sum_j (y_{ij} - \bar{y})^2 = n \sum_i (y_i - \bar{y})^2 + \sum_i \sum_j (y_{ij} - y_i)^2$$

# ANOVA

$$\sum_i \sum_j (y_{ij} - \bar{y})^2 = n \sum_i (y_i - \bar{y})^2 + \sum_i \sum_j (y_{ij} - y_i)^2$$

$$SS_{total} = SS_{fact} + SS_{error}$$

## ANOVA

$$\sum_i \sum_j (y_{ij} - \bar{y})^2 = n \sum_i (y_i - \bar{y})^2 + \sum_i \sum_j (y_{ij} - y_i)^2$$

$$SS_{total} = SS_{fact} + SS_{error}$$

Fuente de variación	Suma de cuadrados	Grados de libertad	Cuadrado medio	F
Intergrupo	$SS_{\text{Factores}}$	$t - 1$	$T = \frac{SS_{\text{Factores}}}{t - 1}$	$F = \frac{T}{E}$
Intragrupo o Error	$SS_{\text{Error}}$	$N - t$	$E = \frac{SS_{\text{Error}}}{N - t}$	
Total	$SS_{\text{Total}}$	$N - 1$		

# Prueba de independencia $\chi^2$

Una prueba muy útil e interesante es la prueba  $\chi^2$  de independencia para variables categóricas.

# Prueba de independencia $\chi^2$

Una prueba muy útil e interesante es la prueba  $\chi^2$  de independencia para variables categóricas.

## Example

En una encuesta electoral realizada a 500 personas, se obtuvo la siguiente distribución en función de sus edades e intención de voto:

# Prueba de independencia $\chi^2$

Una prueba muy útil e interesante es la prueba  $\chi^2$  de independencia para variables categóricas.

## Example

En una encuesta electoral realizada a 500 personas, se obtuvo la siguiente distribución en función de sus edades e intención de voto:

Partido \ Edad	18-35	35-50	50 o más
A	10	40	60
B	15	70	90
C	45	60	35
D	30	30	15



# Prueba de independencia $\chi^2$

Una prueba muy útil e interesante es la prueba  $\chi^2$  de independencia para variables categóricas.

## Example

En una encuesta electoral realizada a 500 personas, se obtuvo la siguiente distribución en función de sus edades e intención de voto:

Partido \ Edad	18-35	35-50	50 o más
A	10	40	60
B	15	70	90
C	45	60	35
D	30	30	15

Determinar si las variables **partido** y **edad** son independientes a una significancia de 5 %.

La anterior es lo que se conoce como **tabla de contingencia**

# Prueba de independencia $\chi^2$

## Example

Siguiendo con el ejemplo, sumamos por fila y por columna en la tabla de contingencia

# Prueba de independencia $\chi^2$

## Example

Siguiendo con el ejemplo, sumamos por fila y por columna en la tabla de contingencia

Partido \ Edad	18-35	35-50	50 o más	Total
A	10	40	60	110
B	15	70	90	175
C	45	60	35	140
D	30	30	15	75
Total	100	200	200	500

# Prueba de independencia $\chi^2$

## Example

Ahora recalculamos los valores esperados asumiendo que las variables son independientes:

# Prueba de independencia $\chi^2$

## Example

Ahora recalculamos los valores esperados asumiendo que las variables son independientes:

Partido \ Edad	18-35	35-50	50 o más	Total
A	22	44	44	110
B	35	70	70	175
C	28	56	56	140
D	15	30	30	75
Total	100	200	200	500

# Prueba de independencia $\chi^2$

## Example

Ahora calculamos el estadístico de prueba

# Prueba de independencia $\chi^2$

## Example

Ahora calculamos el estadístico de prueba

$$J = \sum \frac{(O - E)^2}{E}$$

# Prueba de independencia $\chi^2$

## Example

Ahora calculamos el estadístico de prueba

$$J = \sum \frac{(O - E)^2}{E}$$

Este estadístico se distribuye  $\chi^2$  con  $(m - 1)(n - 1)$  grados de libertad, donde  $m$  y  $n$  es el número de valores que toman las variables partido y edad respectivamente.



# Prueba de independencia $\chi^2$

## Example

Ahora calculamos el estadístico de prueba

$$J = \sum \frac{(O - E)^2}{E}$$

Este estadístico se distribuye  $\chi^2$  con  $(m - 1)(n - 1)$  grados de libertad, donde  $m$  y  $n$  es el número de valores que toman las variables partido y edad respectivamente. En este caso, el número de grados de libertad es  $3 \cdot 2 = 6$ .

# Prueba de independencia $\chi^2$

## Example

Ahora calculamos el estadístico de prueba

$$J = \sum \frac{(O - E)^2}{E}$$

Este estadístico se distribuye  $\chi^2$  con  $(m - 1)(n - 1)$  grados de libertad, donde  $m$  y  $n$  es el número de valores que toman las variables partido y edad respectivamente.

En este caso, el número de grados de libertad es  $3 \cdot 2 = 6$ .

De acuerdo a esto, podemos plantear una prueba de hipótesis:

# Prueba de independencia $\chi^2$

## Example

Ahora calculamos el estadístico de prueba

$$J = \sum \frac{(O - E)^2}{E}$$

Este estadístico se distribuye  $\chi^2$  con  $(m - 1)(n - 1)$  grados de libertad, donde  $m$  y  $n$  es el número de valores que toman las variables partido y edad respectivamente.

En este caso, el número de grados de libertad es  $3 \cdot 2 = 6$ .

De acuerdo a esto, podemos plantear una prueba de hipótesis:

$H_0$ : Las variables son independientes

# Prueba de independencia $\chi^2$

## Example

Ahora calculamos el estadístico de prueba

$$J = \sum \frac{(O - E)^2}{E}$$

Este estadístico se distribuye  $\chi^2$  con  $(m - 1)(n - 1)$  grados de libertad, donde  $m$  y  $n$  es el número de valores que toman las variables partido y edad respectivamente.

En este caso, el número de grados de libertad es  $3 \cdot 2 = 6$ .

De acuerdo a esto, podemos plantear una prueba de hipótesis:

$H_0$ : Las variables son independientes

$H_1$ : Las variables no son independientes

# Prueba de independencia $\chi^2$

## Example

Ahora calculamos el estadístico de prueba

$$J = \sum \frac{(O - E)^2}{E}$$

Este estadístico se distribuye  $\chi^2$  con  $(m - 1)(n - 1)$  grados de libertad, donde  $m$  y  $n$  es el número de valores que toman las variables partido y edad respectivamente.

En este caso, el número de grados de libertad es  $3 \cdot 2 = 6$ .

De acuerdo a esto, podemos plantear una prueba de hipótesis:

$H_0$ : Las variables son independientes

$H_1$ : Las variables no son independientes

En este caso,  $J = 70,86$ , lo que lleva a un  $p$ -valor mucho menor que 0,05, lo que lleva a rechazar la hipótesis nula, esto es, que el partido y la edad son independientes.